


Cardiovascular risks

"I'm going to pump you up. Love, your heart."

Aide médicale avec la régression logistique



Ce projet va vous permettre de mettre en œuvre **une régression logistique** dans le but d'analyser une variable binaire (dont les valeurs seraient VRAI/FAUX, 0/1 ou OUI/NON) en fonction d'une variable explicative quantitative. La régression logistique consiste à prédire des variables binaires et non à prédire des variables continues.

Vous travaillez dans le domaine de la médecine préventive. Votre métier est donc de donner des conseils d'**hygiène de vie** (propreté, mais aussi diététique, encouragement à un sport ou une activité physique, ergonomie et manière de faire des efforts, prévention des comportements à risque, etc.) ainsi que de proposer un accompagnement dans le **dépistage de maladies**



et plus spécifiquement, dans la prévention des risques **cardio-vasculaire**.

Entre 300 000 et 400 000 accidents cardiovasculaires surviennent chaque année en France, dont un tiers sont mortels. **Comment mieux prédire le risque cardiovasculaire ?**

Si plusieurs facteurs de risque sont identifiés, quelles sont les interactions entre ces facteurs ? Les maladies cardiovasculaires, principalement les accidents vasculaires cérébraux (AVC) et les infarctus du myocarde, sont la **deuxième cause de mortalité en France**.

La liste des facteurs de risque cardiovasculaire est malheureusement longue :



Les 12 facteurs de risque constituent ainsi un véritable réseau de facteurs de risque cardiovasculaire.



En fonction de ces interactions, des chercheurs ont pu mettre en évidence **4 groupes de facteurs** de risque :

1. Des **facteurs non modifiables** (le sexe, l'âge et les antécédents familiaux) : ils prédisent d'autres facteurs, mais ne peuvent pas être prédits par d'autres facteurs.
2. Des **facteurs liés au mode de vie** (le tabagisme, la sédentarité, l'alcoolisme) : ils prédisent beaucoup d'autres facteurs (sauf les facteurs non modifiables), mais sont très peu prédits par d'autres facteurs.
3. Des **facteurs cliniques en amont** (les troubles du sommeil, l'obésité, la dépression) : ils prédisent beaucoup d'autres facteurs et sont eux-mêmes prédits par de nombreux facteurs.
4. Des **facteurs cliniques en aval** (l'hypertension artérielle, les dyslipidémies, le diabète) : ils prédisent très peu de facteurs, mais sont en revanche prédits par beaucoup de facteurs.

Pour vous accompagner au mieux dans **votre démarche de prévention de ces risques cardio-vasculaire**, vous avez décidé de développer un **outil** permettant de poser un **diagnostic rapide de risques cardio-vasculaire**. Cet outil mettra en œuvre un algorithme de machine learning de **classification binaire** (prédiction de 0 ou 1) permettant de prédire s'il y a un risque cardio-vasculaire ou s'il n'y en a pas.

Pour pouvoir **entraîner** votre algorithme de classification, vous avez monté un partenariat avec des médecins généralistes de votre ville et ainsi pu



récolter des **données de patients**. Ces données peuvent être récupérées [ici](#) et leur descriptif [ici](#).

Construction du modèle

En vous appuyant sur **les données fournies**, construisez un modèle de régression logistique permettant de **prédire les sujets à risque** !

1. Réalisez une **veille** sur la **régression logistique**.
2. Réalisez un **pré-traitement de vos données**. Analysez les données manquantes, aberrantes et les doublons à l'aide de divers outils. Vos données doivent avoir du **sens dans un contexte médical**.
3. **Visualisez** et **analysez** les données avec les librairies Matplotlib, Seaborn ou Plotly.
4. Réalisez une régression logistique du cas d'étude présenté ci-dessus avec les outils de la librairie **Scikit-Learn**. Testez et modifiez les différents **hyper-paramètres**.
5. Réalisez une régression logistique du cas d'étude présenté ci-dessus avec votre **propre classe** python **sans** utiliser de librairies existantes.
6. **Évaluez** vos résultats avec des mesures de qualité d'un **algorithme de classification supervisée**. Vous devrez utiliser plusieurs métriques d'évaluation (matrice de confusion, l'accuracy, le recall, rapport de classification, ...). Quel est la métrique la plus



adaptée à ce cas d'étude ?

7. **Donnez une prédiction pour si Arthur 53 ans, fumeur, sportif, 175 cm, 85 kg, avec un taux de cholestérol au dessus de la normal et un taux de glucose normal, une tension artérielle systolique dans la moyenne et une pression sanguine diastolique correspondant à la moyenne du 3e quartile (50%-75%) du jeu de données, est un sujet à risques cardio-vasculaire.**
8. **(Bonus) Identifiez un autre algorithme de classification supervisée et suivez les mêmes étapes que ci-dessus.** Comparez leur fonctionnement (forces et faiblesses) ainsi que leurs performances. Concluez le modèle le plus efficace pour la problématique de prédiction d'une classe binaire.

Compétences visées

- Automatiser l'extraction de données
- Développer des règles d'agrégation de données issues de différentes sources
- Organiser et réaliser une veille technique et réglementaire en animant le travail collectif de sélection des sources
- Paramétrer un service d'intelligence artificielle en suivant sa documentation technique et en respectant les spécifications du projet
- Monitorer un modèle d'ia à partir des métriques courantes et spécifiques au projet
- Programmer les tests automatisés d'un modèle d'intelligence artificielle
- Analyser le besoin d'application d'un commanditaire intégrant un service d'ia
- Concevoir le cadre technique d'une application intégrant un service d'ia



- Coordonner la réalisation technique d'une application d'ia
- Développer les composants techniques et les interfaces d'une application

Rendu

L'évaluation de ce projet se fera sur deux aspects :

1. Une présentation explicative de votre travail sous forme de diapositives.
2. Un repository github public nommé **cardio-vasc-risks**, contenant les éléments suivants :
 - a. Un **notebook Python propre et commenté** (introduction, titres des sections, interprétation des visuels, justification des résultats, conclusion, etc) contenant le procédé de développement de votre outil, du nettoyage à la modélisation des données, en passant par l'**analyse exploratoire. Pensez à répondre à la problématique.** Vous pouvez avoir au maximum deux notebooks, un pour l'exploration et l'autre pour la modélisation de données.
 - b. Un fichier **README.md** présentant le contexte du projet, les données et leur analyse, les algorithmes utilisés et une conclusion sur votre travail. Pensez à inclure la veille réalisée.
 - c. **(BONUS)** Un notebook Python du job facultatif.

Base de connaissances

- [Logistic Regression](#)



- [Machine Learning Fundamentals: Cross Validation](#)
- [Metrics to Evaluate your Classification Model to take the right decisions](#)
- [CF Blog : What is Logistic Regression? A Beginner's Guide.](#)
- [Wikipedia on Logistic regression.](#)
- [COURBES ROC](#)
- [Scikit-Learn – GridSearch](#)